FIAP · PÓS TECH · AGENTES DE IA

TECH CHALLENGE · FASE 1 · RELATÓRIO EXECUTIVO

Olist Intelligent Marketplace

Oportunidades de IA Generativa e Agentes de IA para a operação e os indicadores de negócio da Olist

INTEGRANTES

Nome completo do integrante · RM 000000
Nome completo do integrante · RM 000000
Nome completo do integrante · RM 000000
Nome completo do integrante · RM 000000
Nome completo do integrante · RM 000000

LOCAL E DATA

São Paulo
Outubro de 2026

Relatório apresentado como entrega da Fase 1 (Fundamentos de IA e Agentic AI) do Tech Challenge da Pós Tech da FIAP.

RESUMO EXECUTIVO

A Olist conecta pequenos e médios lojistas aos grandes marketplaces do país e, para o consumidor, é ela quem vende. A experiência de compra, porém, depende de milhares de vendedores e de várias transportadoras que a empresa não controla diretamente. Este relatório responde à pergunta proposta para a Fase 1 do Tech Challenge: *como a Olist poderia utilizar IA Generativa e Agentes de IA para melhorar sua operação e seus indicadores de negócio?*

Para responder, analisamos os 99.441 pedidos do conjunto de dados público da empresa, feitos entre setembro de 2016 e outubro de 2018. Quatro números resumem o diagnóstico:

6,8%
das entregas chegaram depois da data prometida. Em março de 2018, foram 19%.

2,3 vs 4,3
nota média dos pedidos atrasados contra a dos pedidos entregues no prazo.

43%
das avaliações de 1 e 2 estrelas vêm de pedidos atrasados ou que não foram entregues.

3,1%
dos clientes voltaram a comprar no período analisado.

A insatisfação se concentra no pós-venda. Prazo descumprido, entrega incompleta e falta de retorno do atendimento aparecem com mais frequência nas reclamações do que defeitos de produto. São falhas de coordenação e de comunicação entre muitos participantes, um tipo de problema em que agentes de IA podem ajudar: acompanham cada pedido individualmente, leem todos os comentários e respondem a qualquer hora.

Propomos três agentes que trabalham de forma coordenada. O **Analista de Reviews** lê e classifica cada avaliação assim que ela chega e aponta causas recorrentes por vendedor, categoria e rota. O **Guardião Logístico** acompanha os pedidos em trânsito, estima o risco de atraso e avisa o cliente antes que o prazo vença. O **SAC Agêntico** resolve no chat as solicitações mais comuns, como status, troca e devolução, dentro da política da empresa, e encaminha as exceções para um atendente.

O efeito esperado é reduzir as avaliações negativas ligadas à entrega, diminuir os contatos repetitivos no atendimento e dar à Olist informação para agir sobre vendedores e transportadoras com desempenho ruim. As metas do capítulo 9 são tratadas como hipóteses a validar em piloto. Recomendamos começar pelo Analista de Reviews, em um piloto de 30 dias sobre a base histórica: é o agente de menor risco, porque não fala diretamente com clientes, e o que gera a informação de que os outros dois dependem.

SUMÁRIO

1 **Introdução** 4
1.1 Contexto da Olist 4
1.2 Desafio e pergunta norteadora 4
1.3 Objetivos 4
1.4 Método 5

2 **Fundamentos: da IA generativa aos agentes** 5
2.1 Aprendizado de máquina e IA generativa 5
2.2 O que caracteriza um agente de IA 6
2.3 Padrões adotados nesta proposta 6

3 **Diagnóstico a partir dos dados** 7
3.1 A base analisada 7
3.2 Crescimento e sazonalidade 8
3.3 Prazo prometido e prazo real 8
3.4 O que dizem as avaliações 9
3.5 Pedidos com mais de um item ou vendedor 11
3.6 Recompra 11
3.7 Vendedores e catálogo 11
3.8 Síntese do diagnóstico 11

4 **Oportunidades e priorização** 12

5 **Mapa de agentes de IA** 13

6 **Arquitetura conceitual inicial** 14
6.1 Exemplo de funcionamento 15

7 **Estruturação de prompts** 16
7.1 Agente 01 – Analista de Reviews 16
7.2 Agente 02 – Guardião Logístico 17
7.3 Agente 03 – SAC Agêntico 18

8 **Governança, riscos e limitações** 19
8.1 Princípios de uso responsável 19
8.2 Matriz de riscos 20
8.3 Limitações deste estudo 20

9 **Impacto esperado e próximos passos** 20
9.1 Roteiro de implantação 20
9.2 Indicadores e metas 21
9.3 Evolução nas próximas fases do curso 22

10 **Vídeo executivo** 22

11 **Considerações finais** 22

Referências 24

1 INTRODUÇÃO

1.1 Contexto da Olist

A Olist funciona como uma loja de departamentos dentro dos grandes marketplaces brasileiros. O lojista assina um único contrato, cadastra seus produtos uma vez e passa a vendê-los nesses canais por meio da loja da Olist. Quando a venda acontece, o vendedor é notificado, separa o pedido e o envia com o apoio dos parceiros logísticos da Olist. Depois da entrega, ou quando a data prevista chega, o cliente recebe por e-mail uma pesquisa de satisfação, na qual dá uma nota de 1 a 5 e pode deixar um comentário (OLIST, 2018).

O modelo dá escala a quem sozinho não teria acesso aos grandes canais, mas cria uma dependência. Para o consumidor, quem vendeu foi a Olist. Um atraso da transportadora ou um item esquecido por um dos mais de três mil vendedores vira uma avaliação negativa para a loja, e a reputação da loja nos marketplaces afeta a visibilidade e a conversão de todos os lojistas que vendem por ela.

1.2 Desafio e pergunta norteadora

Neste trabalho, o grupo atua como uma consultoria contratada para iniciar a jornada de IA da Olist. A pergunta que orienta a Fase 1 é:

> **"Como a Olist poderia utilizar IA Generativa e Agentes de IA para melhorar sua operação e seus indicadores de negócio?"**

Nesta etapa o foco é entender o negócio, identificar oportunidades e desenhar uma visão inicial. Não faz parte do escopo desenvolver software; os agentes são descritos no nível de objetivo, dados, responsabilidades e limites, para que possam ser prototipados nas fases seguintes do curso.

1.3 Objetivos

O objetivo geral é propor um conjunto inicial de agentes de IA para a Olist, fundamentado em evidências do conjunto de dados e ligado a indicadores de negócio. Os objetivos específicos são:

a. diagnosticar os principais problemas da operação a partir do dataset público da empresa;
b. listar e priorizar oportunidades de uso de IA Generativa e de agentes;
c. desenhar o mapa de agentes e a arquitetura conceitual da solução;
d. estruturar os prompts iniciais de cada agente;
e. apontar riscos, indicadores de acompanhamento e próximos passos.

1.4 Método

O trabalho seguiu quatro etapas. Primeiro, exploramos as oito tabelas do dataset com Python e a biblioteca pandas para medir prazos, notas, recompra e desempenho por região, categoria e vendedor. Em seguida, agrupamos por tema os 10.831 comentários de avaliações com nota 1 ou 2, usando regras de palavras-chave definidas a partir dos termos mais frequentes nesses textos. Com o diagnóstico em mãos, listamos as oportunidades e as ordenamos por impacto, viabilidade e risco. Por fim, desenhamos os agentes, a arquitetura e os prompts para as três oportunidades mais bem avaliadas.

Duas definições são usadas ao longo do texto. Consideramos **atrasado** o pedido entregue em data posterior à data estimada informada ao cliente na compra, e **avaliação negativa** a de nota 1 ou 2. O código que gera todos os números e gráficos acompanha este relatório (`analise/analise_olist.py`), o que permite reproduzir a análise.

2 FUNDAMENTOS: DA IA GENERATIVA AOS AGENTES

2.1 Aprendizado de máquina e IA generativa

Russell e Norvig (2022) definem a inteligência artificial como o estudo de agentes que percebem o ambiente e agem para atingir objetivos. Boa parte das aplicações atuais vem do aprendizado de máquina, em que o sistema aprende padrões a partir de exemplos em vez de seguir regras escritas uma a uma. O Quadro 1 resume as três formas clássicas de aprendizado e onde cada uma poderia ser usada na Olist.

Quadro 1 – Paradigmas de aprendizado de máquina e exemplos no contexto da Olist

Paradigma	Como o modelo aprende	Exemplo de aplicação na Olist
Supervisionado	a partir de exemplos já rotulados com a resposta correta	prever se um pedido vai atrasar, treinando com pedidos passados cuja data de entrega já é conhecida
Não supervisionado	encontrando grupos e padrões em dados sem rótulo	agrupar vendedores por perfil de desempenho; detectar comportamentos fora do padrão em pedidos
Por reforço	por tentativa e erro, guiado por recompensas	ajustar regras de roteamento e de frete conforme o resultado observado nas entregas

Fonte: elaborado pelos autores (2026), com base em Russell e Norvig (2022).

A IA generativa é um caso particular. Os grandes modelos de linguagem (LLMs) são treinados com volumes enormes de texto e produzem conteúdo novo a partir de uma instrução em linguagem natural, o *prompt*. Para a Olist, isso significa ler e escrever em português em escala: entender o que um cliente quis dizer em um comentário, redigir uma resposta, resumir milhares de avaliações em poucos parágrafos.

2.2 O que caracteriza um agente de IA

Um assistente generativo responde quando alguém pergunta. Um agente recebe um objetivo e decide os passos para alcançá-lo: consulta dados, usa ferramentas, avalia o resultado e repete o ciclo até concluir a tarefa ou pedir ajuda (WENG, 2023). Quatro componentes aparecem em praticamente todas as descrições de agentes, e o Quadro 2 os ilustra com um dos agentes propostos neste relatório.

Quadro 2 – Componentes de um agente de IA, ilustrados pelo Guardião Logístico

Componente	Função	No Guardião Logístico
Percepção	receber informações do ambiente	eventos de rastreio e mudanças no status do pedido
Raciocínio e planejamento	interpretar a situação e decidir o próximo passo	comparar a posição do pacote com o prazo prometido e estimar o risco
Ferramentas (ação)	agir sobre sistemas externos	enviar mensagem ao cliente; abrir chamado com a transportadora
Memória	guardar o que já aconteceu	registrar que o cliente já foi avisado, para não repetir a mensagem

Fonte: elaborado pelos autores (2026), com base em Weng (2023) e Russell e Norvig (2022).

A diferença prática entre os dois tipos de sistema aparece no Quadro 3.

Quadro 3 – Diferenças entre um assistente generativo e um agente de IA

Aspecto	Assistente generativo	Agente de IA
Início da ação	responde a uma pergunta do usuário	parte de um objetivo ou de um evento, como a mudança no status de um pedido
Memória	limitada à conversa em andamento	histórico persistente do cliente e do pedido
Ferramentas	em geral, nenhuma	consulta sistemas e executa ações dentro de permissões definidas
Tratamento de erros	entrega a resposta, certa ou errada	observa o resultado da ação e pode corrigir o rumo

Fonte: elaborado pelos autores (2026).

Nem todo problema pede um agente. Processos previsíveis, com passos sempre iguais, costumam ser resolvidos com automações simples, que são mais baratas e mais fáceis de auditar. A autonomia de um agente se justifica quando a tarefa exige interpretar situações que mudam de caso para caso (ANTHROPIC, 2024). Usamos esse critério na priorização do capítulo 4.

2.3 Padrões adotados nesta proposta

Raciocinar e agir (ReAct). O modelo alterna pensamento, ação e observação: decide consultar o rastreio, lê o resultado e só então redige a mensagem ao cliente. Como cada passo se apoia em dados efetivamente consultados, o padrão reduz respostas inventadas e deixa o raciocínio registrado para auditoria (YAO *et al.*, 2023).

Geração aumentada por recuperação (RAG). Antes de responder, o agente busca trechos relevantes em uma base de documentos, como a política de trocas ou as regras do Código de Defesa do Consumidor, e responde com base neles (LEWIS *et al.*, 2020). Assim, a regra de devolução aplicada vem do documento oficial, e não do que o modelo "lembra".

Memória. Seguindo a ideia de Park *et al.* (2023), tratamos a memória como um registro de eventos de cada cliente e pedido, recuperado conforme a recência, a importância e a relevância para a situação atual.

Sistemas multiagentes. Em vez de um único agente que faz tudo, vários agentes especializados, cada um com escopo, ferramentas e permissões próprias, trocam informações por meio de um orquestrador e de uma memória comum (WOOLDRIDGE, 2009). Escopos menores tornam cada agente mais fácil de testar e de controlar.

Pessoa no circuito (*human-in-the-loop*). Decisões com impacto financeiro ou de reputação passam pela aprovação de uma pessoa. A autonomia é ampliada aos poucos, à medida que o agente demonstra bom desempenho.

3 DIAGNÓSTICO A PARTIR DOS DADOS

3.1 A base analisada

O *Brazilian E-Commerce Public Dataset by Olist* reúne 99.441 pedidos feitos entre setembro de 2016 e outubro de 2018, com dados anonimizados de 96.096 clientes, 3.095 vendedores e 32.951 produtos de 73 categorias (OLIST, 2018). Os pedidos somam R$ 16,0 milhões em pagamentos, com valor médio de R$ 160,99 e mediano de R$ 105,29. O cartão de crédito responde por 74% dos pagamentos e o boleto, por 19%. O Quadro 4 descreve as tabelas e o uso que fizemos de cada uma.

Quadro 4 – Tabelas do dataset e uso na análise

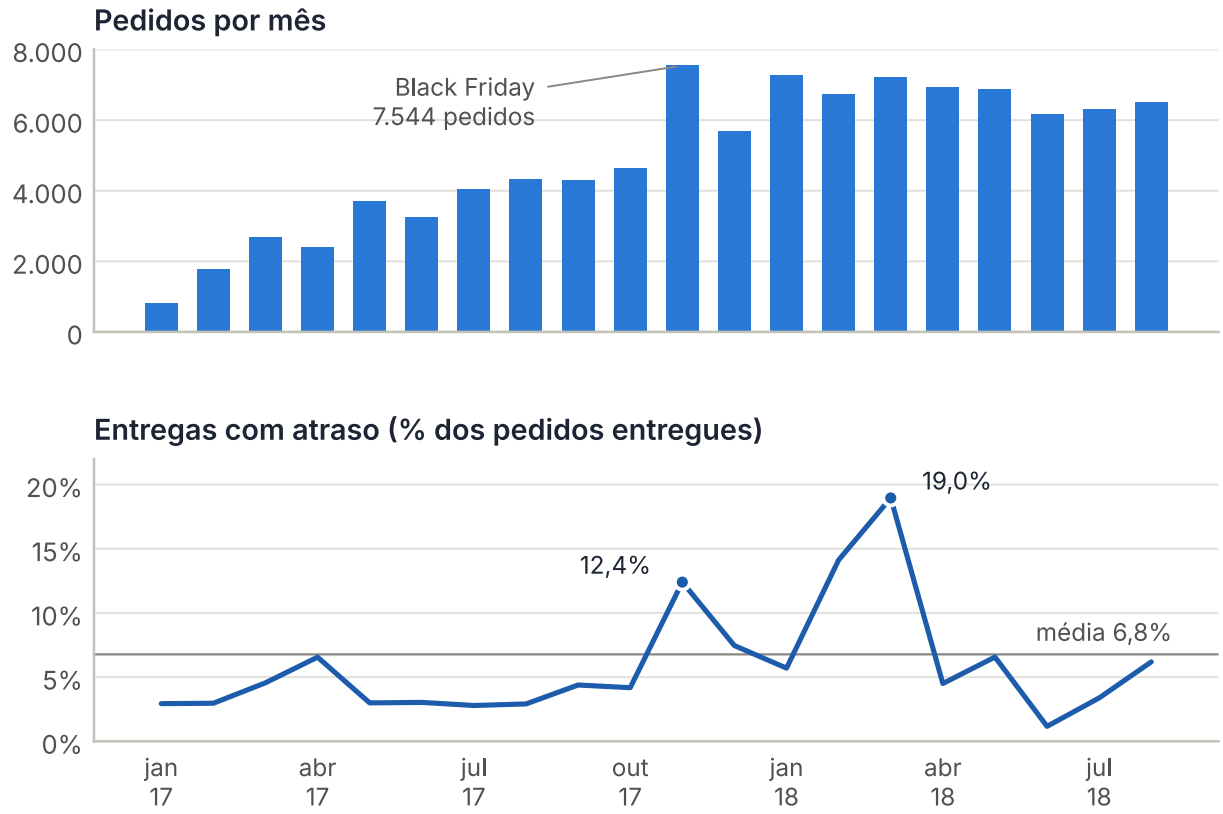
Tabela	Conteúdo	Uso nesta análise
`orders`	99.441 pedidos, com status e datas de compra, postagem, entrega e prazo estimado	prazos, atrasos e sazonalidade
`order_items`	112.650 itens, com preço, frete, vendedor e prazo-limite de postagem	frete, pedidos com vários itens ou vendedores, postagem fora do prazo
`order_payments`	forma de pagamento, número de parcelas e valor	valor dos pedidos e meios de pagamento
`order_reviews`	99.224 avaliações, com nota, título e comentário	satisfação e temas de reclamação
`customers`	cliente e localização (CEP, cidade e UF)	análise regional e recompra
`sellers`	3.095 vendedores e sua localização	concentração e desempenho dos vendedores
`products`	categoria, peso, dimensões e número de fotos	categorias com mais avaliações negativas
`geolocation`	coordenadas aproximadas por prefixo de CEP	reservada para análise de rotas nas próximas fases

Fonte: elaborado pelos autores (2026), com base em Olist (2018).

3.2 Crescimento e sazonalidade

O volume mensal passou de cerca de 800 pedidos em janeiro de 2017 para algo entre 6 e 7 mil por mês ao longo de 2018 (Figura 1). O pico isolado foi novembro de 2017, mês da Black Friday, com 7.544 pedidos. A taxa de atraso acompanhou os momentos de pressão: subiu para 12,4% em novembro de 2017 e chegou a 19,0% em março de 2018, quase o triplo da média do período, de 6,8%.

Figura 1 – Pedidos por mês e percentual de entregas com atraso (jan. 2017 a ago. 2018)



Fonte: elaborado pelos autores (2026), com base em Olist (2018). Foram excluídos 2016 e os meses de setembro e outubro de 2018, com poucos pedidos na base.

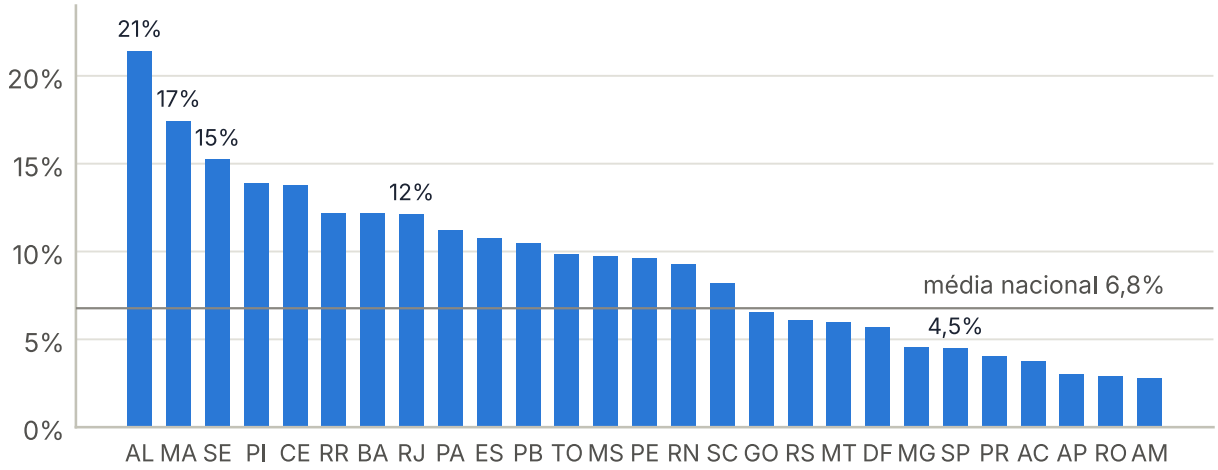
O dataset não traz informação que explique sozinha o pico de fevereiro e março de 2018. O padrão, porém, sugere que a operação perde previsibilidade quando o volume sobe, justamente quando mais clientes são afetados. Um monitoramento que dependa de pessoas olhando pedido por pedido tende a falhar nesses momentos.

3.3 Prazo prometido e prazo real

Na mediana, um pedido levou 10,2 dias para chegar, enquanto o prazo informado na compra foi de 23,2 dias. Quase três em cada quatro pedidos chegaram com uma semana ou mais de antecedência. A promessa de entrega é, portanto, conservadora. Mesmo assim, cerca de 6,5 mil entregas (6,8%) a ultrapassaram, com atraso mediano de 7,5 dias.

O problema é desigual no território (Figura 2). Em Alagoas, 21% das entregas atrasaram; no Maranhão, 17%; em Sergipe, 15%. O Rio de Janeiro merece atenção à parte: com 12% de atraso e mais de 12 mil pedidos entregues, é o segundo estado em número absoluto de pedidos atrasados, atrás apenas de São Paulo, cuja taxa de atraso é de 4,5%.

Figura 2 – Percentual de entregas com atraso por UF do cliente



Fonte: elaborado pelos autores (2026), com base em Olist (2018). Considera 96.470 pedidos entregues.

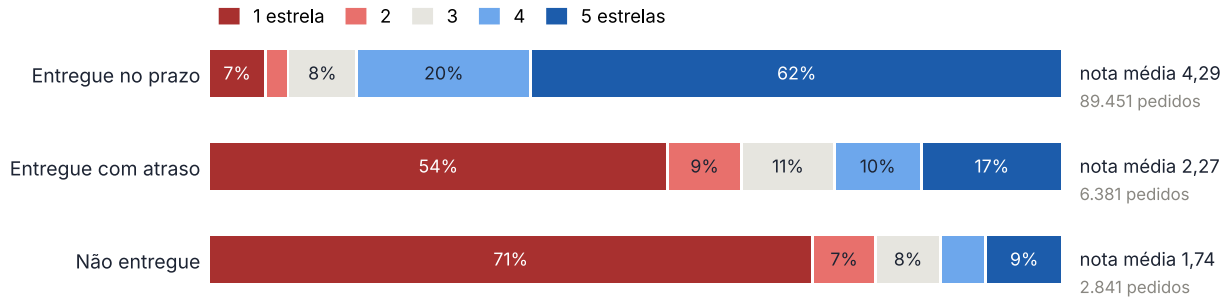
Parte do atraso começa antes do transporte. Em 9,0% dos pedidos entregues, o vendedor postou a mercadoria depois do prazo-limite. Nesses casos, a chance de a entrega atrasar sobe de 5,4% para 20,8%, quase quatro vezes mais. Ainda assim, a postagem tardia aparece em apenas 28% dos pedidos atrasados. O restante do atraso se concentra no trecho da transportadora, que nos pedidos atrasados levou, em mediana, 26 dias, contra 7 dias no conjunto dos pedidos.

> **O que isso significa para um agente.** A postagem fora do prazo e a falta de movimentação no rastreio são sinais disponíveis dias antes de o prazo vencer. Um agente pode acompanhar esses sinais pedido a pedido e agir enquanto ainda há tempo de avisar o cliente ou cobrar o vendedor e a transportadora.

3.4 O que dizem as avaliações

Das 99.224 avaliações, 14,7% têm nota 1 ou 2 e 57,8% têm nota 5. A nota cai drasticamente quando a entrega falha (Figura 3). Pedidos entregues no prazo têm nota média 4,29; com atraso, 2,27; os que não chegaram a ser entregues, 1,74. Entre os pedidos atrasados, 62% receberam 1 ou 2 estrelas, contra 9% dos entregues no prazo.

Figura 3 – Distribuição das notas segundo a situação da entrega



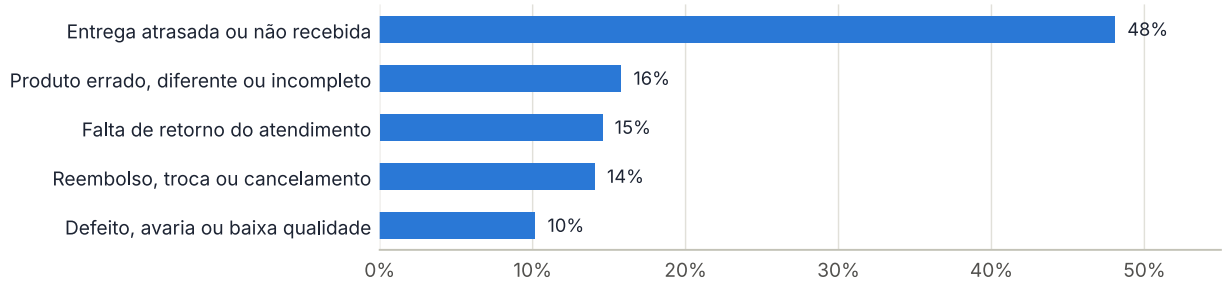
Fonte: elaborado pelos autores (2026), com base em Olist (2018). "Não entregue" inclui pedidos cancelados, indisponíveis e ainda em trânsito no fim da base.

Visto pelo outro lado, 43% das avaliações negativas vêm de pedidos atrasados (27%) ou não entregues (15%). Os outros 57% vêm de pedidos que chegaram no prazo, o que aponta para problemas de produto, de separação do pedido ou de atendimento. Três quartos das avaliações negativas trazem comentário escrito, e são esses textos que mostram o que deu errado:

> *"Comprei duas mochilas, recebi apenas uma, o natal está chegando e até agora nada!"*
>
> *"Estou esperando há mais de vinte dias e ainda não recebi meu produto e não consigo nenhuma informação."*
>
> *"pedi duas unidades do mesmo produto e só veio uma unidade e ninguém me da um retorno"*
>
> Comentários de avaliações com nota 1 ou 2, reproduzidos sem correção (OLIST, 2018).

Classificamos os 10.831 comentários negativos por tema (Figura 4). Como um mesmo comentário pode citar mais de um problema, os percentuais somam mais de 100%. Quase metade fala de entrega, seja atraso ou não recebimento. Em seguida aparecem produto errado, diferente ou incompleto (16%), falta de retorno do atendimento (15%), pedidos de reembolso, troca ou cancelamento (14%) e defeito ou avaria (10%).

Figura 4 – Temas citados nos comentários de avaliações com nota 1 ou 2



Fonte: elaborado pelos autores (2026), com base em Olist (2018). Classificação por palavras-chave; um comentário pode ter mais de um tema.

A classificação por palavras-chave é aproximada e serve para dimensionar o problema, não para uso operacional. Ainda assim, deixa claro que os comentários explicam boa parte da insatisfação e que valeria a pena lê-los de forma sistemática, o que é inviável manualmente no volume da Olist.

3.5 Pedidos com mais de um item ou vendedor

Cerca de 10% dos pedidos têm mais de um item. Neles, a proporção de avaliações negativas é de 27,6%, mais que o dobro da observada em pedidos de item único (12,7%). Quando o pedido envolve mais de um vendedor, situação de 1,3% dos pedidos, a proporção chega a 47%. Os itens saem de lugares diferentes e chegam em datas diferentes, e o cliente, que não foi avisado disso, entende que recebeu o pedido incompleto. É sobretudo uma falha de comunicação, que um aviso proativo poderia evitar.

3.6 Recompra

Apenas 3,1% dos 96.096 clientes fizeram mais de um pedido no período. Considerando só quem comprou pela primeira vez até fevereiro de 2018, e portanto teve ao menos seis meses para voltar, a taxa sobe para 4,1%. Parte desse resultado é estrutural, porque o cliente compra dentro do marketplace e pode nem perceber que a loja é a Olist. Mesmo assim, a experiência de entrega pesa: entre esses clientes, os que tiveram o primeiro pedido atrasado recompraram 3,1%, contra 4,1% dos que receberam no prazo, uma recompra cerca de 24% menor. Trata-se de uma correlação, pois a análise não isola outros fatores, mas ela reforça a ligação entre entrega e retenção.

3.7 Vendedores e catálogo

A base de vendedores é concentrada. Seis em cada dez estão em São Paulo, e os 10% de maior faturamento respondem por 67% da receita de produtos. Isso facilita a ação, porque acompanhar algumas centenas de vendedores cobre a maior parte do volume. Entre as categorias com pelo menos 500 pedidos, móveis de escritório tem a maior proporção de avaliações negativas (22,6%), seguida de cama, mesa e banho (16,8%), que é também a categoria mais vendida, e de móveis e decoração (16,7%). São produtos volumosos ou que dependem de medidas e cores corretas, o que sugere investigar a embalagem e a descrição dos anúncios. Há ainda 1,9% de produtos sem categoria cadastrada, um sinal de qualidade de catálogo a acompanhar.

3.8 Síntese do diagnóstico

O Quadro 5 reúne os problemas identificados, a evidência que os sustenta e a oportunidade de IA associada a cada um.

Quadro 5 – Problemas identificados, evidências e oportunidades de IA

Problema	Evidência no dataset	Efeito no negócio	Oportunidade de IA
Atrasos concentrados em regiões e picos	6,8% de atraso; 21% em AL; 19% em mar./2018; postagem tardia quase quadruplica o risco	avaliações negativas, contatos no atendimento e cancelamentos	monitorar cada pedido e agir antes de o prazo vencer
Insatisfação registrada em texto e pouco aproveitada	14,7% de notas 1 e 2; 10.831 comentários negativos	perda de reputação; problemas de vendedor percebidos tarde	classificar avaliações e apontar causas por vendedor, categoria e rota
Pós-venda com falhas de comunicação	15% dos comentários negativos citam falta de retorno; 47% de notas baixas em pedidos com mais de um vendedor	retrabalho no atendimento e escalada da insatisfação	atendimento automatizado com acesso ao histórico do pedido

Problema	Evidência no dataset	Efeito no negócio	Oportunidade de IA
Baixa recompra	3,1% dos clientes compram de novo; recompra 24% menor após atraso	custo de aquisição alto por venda	relacionamento personalizado no pós-venda
Qualidade do catálogo em algumas categorias	22,6% de notas baixas em móveis de escritório; 1,9% de produtos sem categoria	devoluções e avaliações negativas	revisão assistida de anúncios

Fonte: elaborado pelos autores (2026), com base em Olist (2018).

4 OPORTUNIDADES E PRIORIZAÇÃO

Do diagnóstico saíram seis oportunidades. Avaliamos cada uma em três critérios, com notas de 1 a 5: o **impacto** esperado nos indicadores do negócio; a **viabilidade** com os dados e sistemas que a Olist já possui; e o **risco** de uma decisão errada do agente, em que nota alta significa risco baixo. A soma das notas orienta a ordem de implantação (Tabela 1).

Tabela 1 – Priorização das oportunidades de IA

Oportunidade	Impacto	Viabilidade	Risco (5 = baixo)	Total	Decisão
Análise automática de avaliações	4	5	5	**14**	priorizada
Monitoramento proativo de entregas	5	4	4	**13**	priorizada
Atendimento, trocas e devoluções no chat	5	3	3	**11**	priorizada
Relacionamento e estímulo à recompra	4	3	4	**11**	fases seguintes
Revisão assistida de anúncios	3	4	4	**11**	fases seguintes
Previsão de demanda para vendedores	3	2	4	**9**	fases seguintes

Fonte: elaborado pelos autores (2026).

Três oportunidades empataram com 11 pontos. Escolhemos o atendimento por dois motivos: tem o maior impacto, já que falta de retorno e dificuldades com troca e reembolso estão entre as reclamações mais citadas, e completa os outros dois agentes, usando a informação que eles produzem. O relacionamento para recompra fica para a Fase 2 porque depende de um pós-venda estável. Estimular a segunda compra de quem teve uma primeira experiência ruim tende a dar pouco resultado.

Os três agentes escolhidos cobrem as etapas em que a experiência do cliente mais se deteriora, ou seja, entrega, avaliação e atendimento, e se reforçam mutuamente: o que um aprende serve de entrada para o outro. A sequência de implantação segue a ordem da Tabela 1, do menor para o maior risco.

5 MAPA DE AGENTES DE IA

A Figura 5 apresenta os três agentes propostos, com objetivo, problema resolvido, usuários envolvidos e benefício esperado, e o Quadro 6 define o que cada um pode fazer sozinho, o que depende de aprovação humana e os principais riscos. Os números citados vêm do diagnóstico do capítulo 3.

Figura 5 – Mapa dos agentes de IA propostos para a Olist

AGENTE 01

Analista de Reviews

OBJETIVO

Ler cada avaliação assim que chega, classificar o sentimento e a causa do problema e consolidar padrões por vendedor, categoria e rota.

PROBLEMA RESOLVIDO

14,7% das avaliações são negativas e três quartos delas trazem comentário. Sem leitura sistemática, problemas recorrentes de um vendedor ou produto demoram a ser percebidos.

USUÁRIOS ENVOLVIDOS

Equipe de qualidade do marketplace, gestão de vendedores, vendedores (por meio de um painel) e diretoria (resumo semanal).

BENEFÍCIO ESPERADO

Problemas detectados em dias, e não em semanas; prioridade clara de quais vendedores e categorias tratar; insumo para os outros dois agentes.

AGENTE 02

Guardião Logístico

OBJETIVO

Acompanhar os pedidos em trânsito, estimar o risco de atraso e agir antes do vencimento do prazo: avisar o cliente, cobrar a postagem do vendedor e acionar a transportadora.

PROBLEMA RESOLVIDO

6,8% das entregas atrasam, com até 21% em alguns estados e 19% em meses de pico. Pedidos atrasados têm nota média 2,3, contra 4,3 dos entregues no prazo.

USUÁRIOS ENVOLVIDOS

Clientes, equipe de operações logísticas, vendedores e transportadoras parceiras.

BENEFÍCIO ESPERADO

Cliente informado antes de reclamar, menos contatos do tipo “onde está meu pedido” e menos avaliações negativas causadas por atraso.

AGENTE 03

SAC Agêntico

OBJETIVO

Atender o cliente no chat e no WhatsApp, informar a situação do pedido e conduzir trocas, devoluções e cancelamentos dentro da política, encaminhando as exceções a um atendente.

PROBLEMA RESOLVIDO

Falta de retorno (15%) e dificuldades com reembolso, troca ou cancelamento (14%) estão entre as reclamações mais citadas. Pedidos não entregues têm nota média 1,7.

USUÁRIOS ENVOLVIDOS

Clientes, analistas de atendimento (casos escalados), financeiro (estornos) e vendedores.

BENEFÍCIO ESPERADO

Resposta imediata a qualquer hora, política aplicada de forma consistente e atendentes dedicados aos casos que exigem julgamento.

Fonte: elaborado pelos autores (2026).

Quadro 6 – Autonomia, limites e riscos de cada agente

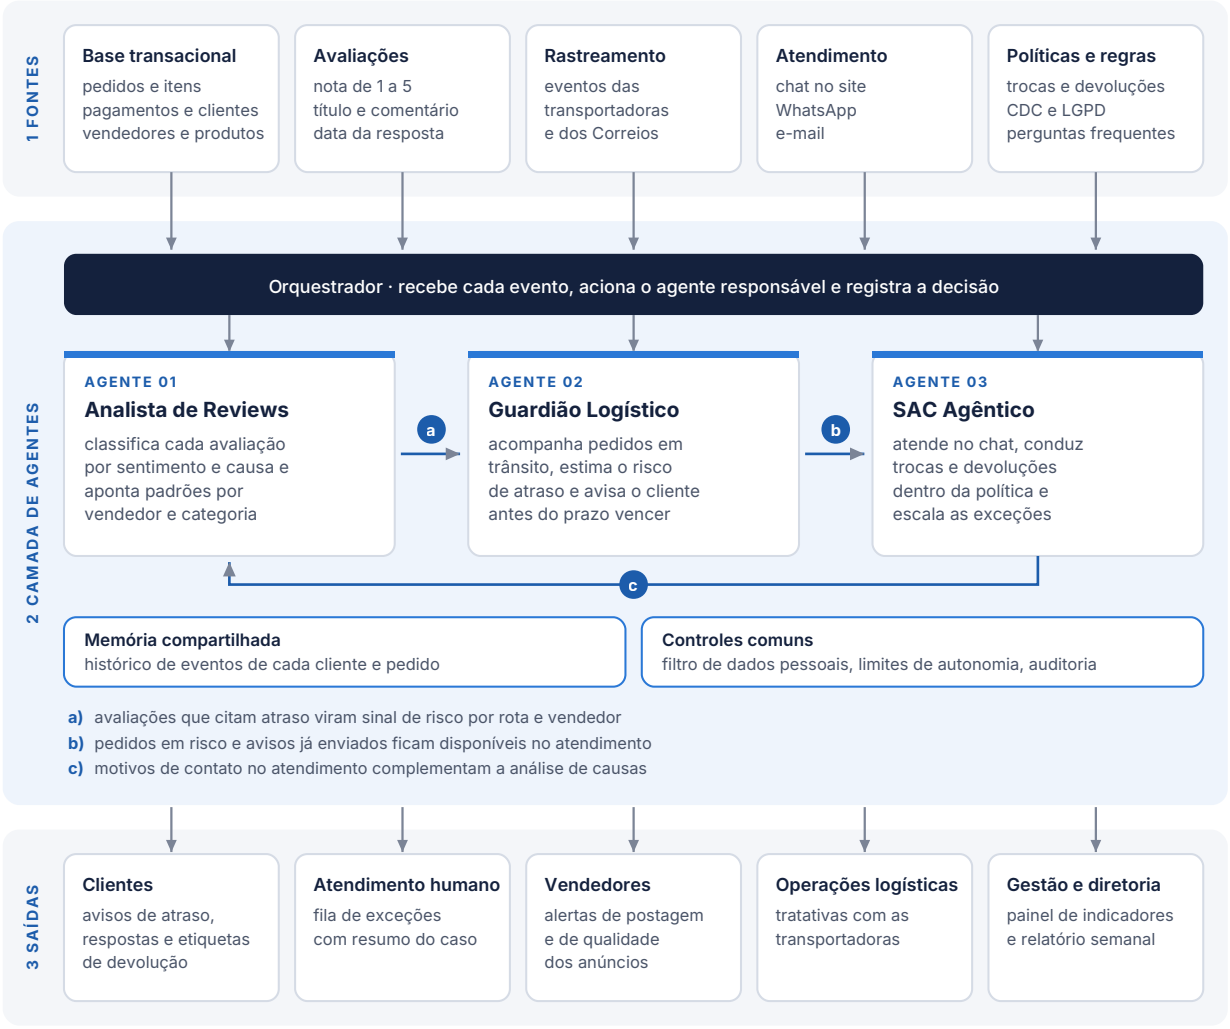
	Analista de Reviews	Guardião Logístico	SAC Agêntico
Autonomia	baixa: analisa e recomenda	média: envia avisos padronizados	média: resolve casos previstos na política
Age sem aprovação	classificar avaliações; gerar alertas e relatórios	avisar o cliente com modelo aprovado; lembrar o vendedor da postagem; abrir chamado com a transportadora	informar status; aprovar troca ou devolução elegível de até R$ 500; gerar etiqueta de postagem
Exige aprovação humana	qualquer medida contra um vendedor	compensação financeira ao cliente; alteração do prazo prometido	valores acima de R$ 500; casos fora da política; cliente que pede um atendente
Principais riscos	classificação errada (ironia, gírias); julgamento injusto de vendedor	alarme falso; nova data que também não se cumpre	aprovação indevida; promessa que a empresa não cumpre; exposição de dados pessoais

Fonte: elaborado pelos autores (2026).

6 ARQUITETURA CONCEITUAL INICIAL

A Figura 6 mostra como os agentes se conectam às fontes de dados e a quem entregam resultados. O desenho é conceitual: não define fornecedores nem tecnologias, que serão escolhidos na fase de prototipação. A arquitetura tem três camadas.

Figura 6 – Arquitetura conceitual da solução multiagente



Fonte: elaborado pelos autores (2026).

A primeira camada reúne as **fontes de dados**: a base transacional (pedidos, itens, pagamentos, clientes, vendedores e produtos), as avaliações, os eventos de rastreamento das transportadoras, as mensagens dos canais de atendimento e os documentos de política, que alimentam a busca por RAG.

Na segunda camada, um **orquestrador** recebe cada evento, como uma nova avaliação, uma mudança no rastreio ou uma mensagem de cliente, e aciona o agente responsável. Os três agentes compartilham uma memória com o histórico de cada cliente e pedido, e todas as chamadas passam pelos mesmos controles: remoção de dados pessoais desnecessários antes do envio ao modelo, limites de autonomia e registro das decisões.

A terceira camada reúne as **saídas e os usuários**: mensagens e etiquetas para clientes, uma fila de exceções com o caso resumido para o atendimento humano, alertas para vendedores e para a operação logística, e um painel de indicadores para a gestão. O Quadro 7 detalha as entradas, as saídas e as interações de cada agente.

Quadro 7 – Entradas, saídas e interações de cada agente

Agente	Entradas	Saídas	Interage com
Analista de Reviews	avaliações (nota e comentário); dados do pedido, do produto e do vendedor	classificação de cada avaliação; alertas por vendedor e categoria; relatório semanal	envia ao Guardião os padrões de atraso por rota e vendedor; recebe do SAC os motivos de contato
Guardião Logístico	prazos do pedido; eventos de rastreio; prazo-limite de postagem; histórico de atraso por rota	aviso ao cliente; lembrete ao vendedor; chamado com a transportadora	registra na memória os pedidos em risco e os avisos enviados, consultados pelo SAC
SAC Agêntico	mensagem do cliente; histórico do pedido; trechos da política (RAG); pagamentos	resposta ao cliente; etiqueta de devolução; caso escalado com resumo	usa a memória alimentada pelo Guardião; envia ao Analista os motivos de contato

Fonte: elaborado pelos autores (2026).

6.1 Exemplo de funcionamento

Para tornar o desenho concreto, acompanhamos um pedido de jogo de cama, da categoria mais vendida, comprado por uma cliente de Maceió, capital do estado com a maior taxa de atraso da base.

1. **Postagem atrasada.** O vendedor não posta o pedido até o prazo-limite. O Guardião Logístico detecta o evento, envia um lembrete ao vendedor e marca o pedido como risco médio.
2. **Pacote parado.** Dois dias depois, o rastreio mostra o pacote parado no centro de distribuição. O risco passa a alto. O Guardião avisa a cliente pelo WhatsApp, com a nova previsão de entrega, e abre um chamado com a transportadora.
3. **Contato da cliente.** A cliente responde perguntando se pode cancelar. O SAC Agêntico encontra na memória o histórico do atraso, explica as opções e, como o valor está abaixo de R$ 500, processa o cancelamento sem passar pela fila.
4. **Aprendizado.** Se a cliente optar por esperar e depois avaliar o pedido com nota baixa, o Analista de Reviews classifica a causa como atraso na entrega e soma o caso às estatísticas da rota e do vendedor. Se o padrão se repetir, a gestão de vendedores recebe um alerta.

7 ESTRUTURAÇÃO DE PROMPTS

Os prompts a seguir são instruções de sistema, isto é, o texto fixo que define o papel e as regras de cada agente. Todos seguem a mesma estrutura: papel, dados recebidos, tarefa, regras e formato da resposta. Pedir a resposta em JSON permite que outros sistemas leiam o resultado e que se verifique automaticamente se o agente respondeu no formato combinado. Os campos entre chaves, como `{comentario}`, são preenchidos pelo orquestrador a cada execução.

7.1 Agente 01 – Analista de Reviews

a) Objetivo do prompt. Classificar uma avaliação quanto a sentimento, causa principal e urgência, e indicar a área responsável e a ação sugerida.

b) Contexto fornecido. Identificador do pedido; nota; comentário; categoria do produto; situação da entrega e dias de atraso; quantidade de itens e de vendedores no pedido.

c) Instrução principal.

```
Você é o Analista de Reviews da Olist, uma loja que reúne milhares de pequenos
vendedores nos grandes marketplaces. Sua função é entender por que o cliente
ficou insatisfeito e indicar quem deve agir.

Dados da avaliação:
- Pedido: {id_pedido}
- Nota: {nota} de 5
- Comentário: "{comentario}"
- Categoria do produto: {categoria}
- Situação da entrega: {situacao_entrega} ({dias_atraso} dias de atraso)
- Itens no pedido: {qtd_itens}, de {qtd_vendedores} vendedor(es)

Tarefa:
1. Classifique o sentimento como positivo, neutro ou negativo, considerando o
   texto e não apenas a nota.
2. Se houver problema, escolha a causa principal entre: atraso na entrega,
   pedido não recebido, entrega parcial, produto errado ou diferente do anúncio,
   defeito ou avaria, atendimento, outro.
3. Defina a urgência: alta se o cliente ainda não recebeu o produto ou pede
   reembolso; média se recebeu com problema; baixa nos demais casos.
4. Indique a área responsável (logística, vendedor, atendimento ou catálogo) e
   sugira uma ação em até 25 palavras.

Regras:
- Use apenas as informações fornecidas. Se o comentário estiver vazio ou for
  ambíguo, use a causa "outro" e confiança "baixa".
- Não inclua nome, telefone, e-mail ou documento do cliente na resposta.
- Responda somente com o JSON no formato indicado, sem texto adicional.
```

d) Resultado esperado. Para o comentário real *"pedi duas unidades do mesmo produto e só veio uma unidade e ninguém me da um retorno"*, em um pedido de dois itens entregue no prazo, a saída esperada é:

```
{
  "id_pedido": "a3f9c1e2",
  "sentimento": "negativo",
  "causa_principal": "entrega parcial",
  "causa_secundaria": "atendimento",
  "urgencia": "alta",
  "area_responsavel": "vendedor",
  "acao_sugerida": "Confirmar com o vendedor o envio da segunda unidade e informar o cliente sobre
    a nova data ou o reembolso parcial.",
  "confianca": "alta"
}
```

7.2 Agente 02 – Guardião Logístico

a) Objetivo do prompt. Avaliar o risco de atraso de um pedido em trânsito e decidir quais ações tomar: avisar o cliente, cobrar o vendedor ou acionar a transportadora.

b) Contexto fornecido. Datas de compra e de entrega prometida; prazo-limite e data efetiva de postagem; último evento de rastreio; UF de origem e de destino; taxa histórica de atraso para o destino; avisos já enviados ao cliente (memória).

c) Instrução principal.

```
Você é o Guardião Logístico da Olist. Seu objetivo é evitar que o cliente seja
surpreendido por um atraso. Você acompanha pedidos em trânsito e decide se é
preciso agir.

Dados do pedido:
- Pedido: {id_pedido} | Compra: {data_compra} | Entrega prometida: {data_prometida}
- Postagem: limite em {limite_postagem}, realizada em {data_postagem}
- Último evento de rastreio: "{ultimo_evento}" em {data_evento}
- Rota: {uf_origem} para {uf_destino} (destino com {taxa_atraso_destino}% de atraso histórico)
- Avisos já enviados ao cliente: {avisos_anteriores}

Tarefa:
1. Classifique o risco de atraso como baixo, médio ou alto e explique o motivo
   em uma frase.
2. Se o risco for médio ou alto e o cliente ainda não tiver sido avisado,
   redija uma mensagem de WhatsApp de até 300 caracteres, em tom cordial e sem
   jargão. Use o marcador {primeiro_nome} no lugar do nome do cliente.
3. Se a postagem ainda não tiver sido feita e o prazo-limite já tiver passado,
   gere um lembrete ao vendedor.
4. Se o atraso previsto for maior que 3 dias, indique a abertura de chamado com
   a transportadora.

Regras:
- Nunca prometa compensação, desconto ou data que não esteja nos dados.
- Não envie mais de um aviso ao mesmo cliente em um intervalo de 48 horas.
- Responda somente com o JSON no formato indicado, sem texto adicional.
```

d) Resultado esperado. Pedido de São Paulo para Alagoas, postado dois dias depois do limite e parado há quatro dias no centro de distribuição. Como a postagem já foi feita, não há lembrete ao vendedor; como o atraso previsto passa de 3 dias, abre-se o chamado. O sistema substitui o marcador pelo nome do cliente só no momento do envio, de modo que o modelo não tem acesso a esse dado.

```
{
  "id_pedido": "7b21e0d4",
  "risco_atraso": "alto",
  "motivo": "Postagem 2 dias após o limite e pacote parado há 4 dias; destino AL tem 21% de atraso
    histórico.",
  "dias_atraso_previstos": 5,
  "mensagem_cliente": "Olá, {primeiro_nome}! Seu pedido teve um atraso no transporte e a nova
    previsão de entrega é 18/10. Já estamos acompanhando com a transportadora e avisaremos qualquer
    novidade por aqui.",
  "lembrete_vendedor": null,
  "abrir_chamado_transportadora": true
}
```

7.3 Agente 03 – SAC Agêntico

a) Objetivo do prompt. Resolver no chat solicitações de status, troca, devolução e cancelamento conforme a política da Olist e encaminhar a um atendente o que estiver fora das regras.

b) Contexto fornecido. Mensagem do cliente; dados do pedido (itens, valor, datas e situação); histórico do cliente e avisos já enviados (memória); trechos da política de trocas e devoluções recuperados da base de conhecimento.

c) Instrução principal.

```
Você é o assistente virtual de atendimento da Olist e conversa com clientes
pelo chat e pelo WhatsApp. Resolva o que estiver ao seu alcance e seja
transparente quando precisar passar o caso para um atendente.

Informações disponíveis:
- Mensagem do cliente: "{mensagem}"
- Pedido: {id_pedido} | Valor: R$ {valor} | Entregue em: {data_entrega}
- Histórico do cliente e do pedido: {memoria}
- Política aplicável: {trechos_politica}

Tarefa:
1. Identifique a intenção: consultar status, trocar, devolver por
   arrependimento, relatar defeito, cancelar ou outra.
2. Verifique a elegibilidade usando apenas a política fornecida. A devolução
   por arrependimento vale por 7 dias a partir do recebimento (CDC, art. 49).
3. Se o caso for elegível e o valor for de até R$ 500, aprove e acione a
   ferramenta gerar_etiqueta_devolucao.
4. Encaminhe para um atendente se o valor passar de R$ 500, se a política não
   cobrir o caso ou se o cliente pedir para falar com uma pessoa.
5. Escreva a resposta ao cliente em linguagem simples, em até 4 frases.

Regras:
- Apresente-se como assistente virtual na primeira mensagem.
- Não invente prazos, valores ou regras que não estejam nas informações acima.
- Não peça nem repita CPF, endereço ou dados de cartão.
- Responda somente com o JSON no formato indicado, sem texto adicional.
```

d) Resultado esperado. Cliente pede para devolver, por arrependimento, um produto de R$ 189,90 recebido há três dias:

```
{
  "id_atendimento": "chat-55120",
  "intencao": "devolver por arrependimento",
  "elegivel": true,
  "acao_executada": "gerar_etiqueta_devolucao",
  "codigo_postagem": "LR482913057BR",
  "encaminhar_humano": false,
  "motivo_encaminhamento": null,
  "resposta_cliente": "Pronto, sua devolução foi aprovada! Enviamos a etiqueta de postagem para o
    seu e-mail; é só levar o produto embalado a uma agência dos Correios. O estorno é feito assim
    que o vendedor receber o item, conforme a nossa política de devolução."
}
```

Os três prompts compartilham três cuidados: limitar o agente aos dados fornecidos, fixar o formato da resposta e deixar explícito quando ele deve parar e chamar uma pessoa. Antes de qualquer uso real, cada prompt seria testado contra uma amostra do histórico. No caso do Analista de Reviews, por exemplo, a classificação do agente seria comparada com a de analistas humanos em algumas centenas de avaliações.

8 GOVERNANÇA, RISCOS E LIMITAÇÕES

8.1 Princípios de uso responsável

Proteção de dados. Os agentes recebem apenas os dados necessários para cada tarefa. Nome, CPF, telefone e endereço são removidos ou trocados por marcadores antes do envio ao modelo e reinseridos depois, no momento do envio da mensagem, como no exemplo do Guardião Logístico. O tratamento se apoia na execução do contrato com o cliente e no legítimo interesse, previstos no art. 7º da Lei Geral de Proteção de Dados (BRASIL, 2018), e os registros seguem prazos de retenção definidos.

Permissões mínimas. Cada agente acessa somente o que precisa. O Analista de Reviews apenas lê dados. O Guardião envia mensagens a partir de modelos aprovados. Só o SAC aciona ferramentas que geram custo, como etiquetas e estornos, e sempre dentro de limites de valor.

Regras críticas verificadas por código. Limites como o valor de R$ 500 e o prazo de 7 dias são conferidos por regras fixas no sistema, e não apenas pela instrução ao modelo. Se a resposta do agente violar uma regra, a ação é bloqueada e o caso vai para um atendente.

Transparência e rastreabilidade. O cliente sabe quando conversa com um assistente virtual e pode pedir um atendente a qualquer momento. Cada decisão fica registrada com os dados usados e a justificativa, o que permite auditar e corrigir erros.

Para as fases seguintes, propomos adotar como referência o *AI Risk Management Framework* do NIST (2023) e a norma ISO/IEC 42001 (INTERNATIONAL ORGANIZATION FOR STANDARDIZATION, 2023), que organizam papéis, avaliação de riscos e monitoramento contínuo de sistemas de IA.

8.2 Matriz de riscos

Quadro 8 – Principais riscos, probabilidade, impacto e mitigação

Risco	Probabilidade	Impacto	Mitigação
Resposta inventada, como uma regra de devolução inexistente	média	alto	política recuperada da base oficial (RAG); proibição explícita no prompt; validação do formato; revisão por amostragem
Exposição de dados pessoais	baixa	alto	remoção de dados pessoais antes do modelo; acesso mínimo; contrato com o fornecedor do modelo vedando a retenção dos dados
Aprovação indevida de devolução ou compensação	média	médio	limite de R$ 500; elegibilidade conferida por regras fixas; auditoria semanal por amostragem
Alarme falso de atraso	média	baixo	aviso apenas com risco médio ou alto; no máximo um aviso a cada 48 horas; calibração com o histórico
Julgamento injusto de um vendedor	baixa	médio	nenhuma medida automática; revisão humana antes de qualquer ação
Falha de sistemas externos (rastreio, Correios)	média	médio	novas tentativas automáticas, fila de mensagens e encaminhamento ao atendimento humano
Rejeição por clientes ou pela equipe interna	média	médio	opção de falar com atendente; participação da equipe desde o piloto; comunicação clara do papel dos agentes

Fonte: elaborado pelos autores (2026).

8.3 Limitações deste estudo

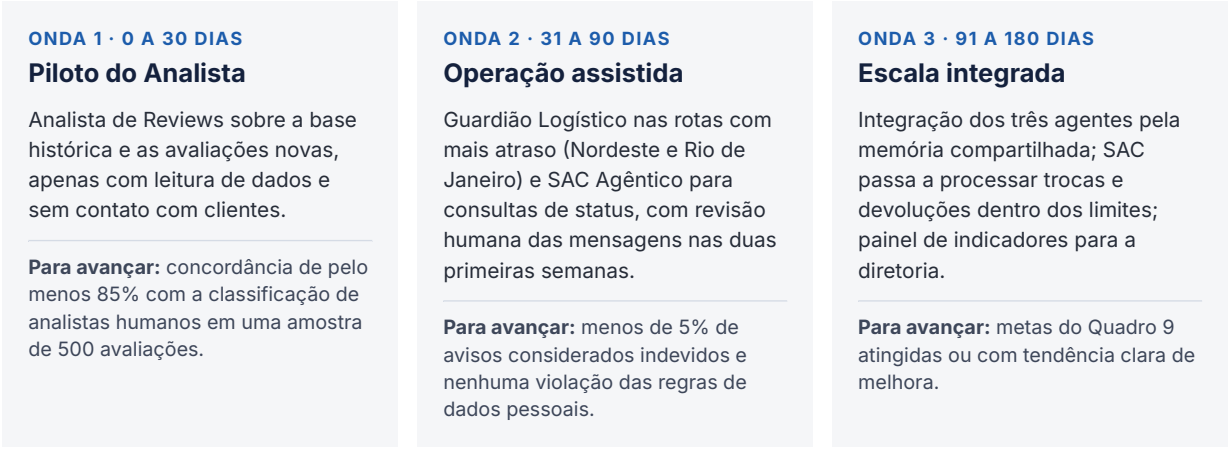
- Os dados cobrem de 2016 a 2018. Volumes, prazos e canais mudaram desde então (o Pix, por exemplo, ainda não existia). Os números servem como linha de base de referência e devem ser atualizados com dados atuais da empresa.
- O dataset não traz custos nem volume de atendimento, nem o detalhe dos eventos de rastreio. Por isso não estimamos a economia em reais.
- A classificação de temas por palavras-chave é aproximada e serve para dimensionar o problema, não para uso operacional.
- As relações entre atraso, nota e recompra são correlações; outros fatores não foram isolados.
- Na anonimização, os nomes de empresas citados nos comentários foram trocados por nomes de casas de *Game of Thrones*, o que limita algumas leituras dos textos.

9 IMPACTO ESPERADO E PRÓXIMOS PASSOS

9.1 Roteiro de implantação

Propomos implantar os agentes em três ondas (o termo evita confusão com as fases do curso). Cada onda só começa quando a anterior atinge o critério de avanço definido, e as metas de cada indicador estão na seção 9.2.

Figura 7 – Roteiro de implantação em três ondas



Fonte: elaborado pelos autores (2026).

9.2 Indicadores e metas

O dataset permite medir a linha de base da maioria dos indicadores relevantes. As metas do Quadro 9 são hipóteses para o piloto, a validar com dados atuais da Olist. Preferimos metas modestas e mensuráveis a promessas difíceis de verificar.

Quadro 9 – Indicadores, linha de base e metas para o piloto

Indicador	Linha de base (2016–2018)	Meta para o piloto	Agente
Entregas com atraso	6,8% (até 19% em meses de pico)	−1 ponto percentual nas rotas monitoradas	Guardião
Pedidos postados fora do prazo-limite	9,0%	reduzir à metade	Guardião
Notas 1 e 2 entre pedidos atrasados	62%	abaixo de 50%	Guardião e SAC
Notas 1 e 2 no total de avaliações	14,7%	abaixo de 13%	os três
Avaliações negativas classificadas e encaminhadas	não medido no dataset	100%, em até 24 horas	Analista
Contatos resolvidos sem atendente	a medir no piloto	50% dos contatos elegíveis	SAC
Tempo até a primeira resposta	a medir no piloto	menos de 1 minuto	SAC
Recompra em até 6 meses	4,1%	acompanhar; meta definida na Fase 2	os três

Fonte: elaborado pelos autores (2026), com linha de base calculada a partir de Olist (2018).

O indicador mais sensível ao trabalho dos agentes é a proporção de notas baixas entre pedidos atrasados. Avisar o cliente antes do prazo não elimina o atraso, mas muda a experiência: o cliente deixa de ser surpreendido e recebe uma explicação e uma nova data. Como hoje 62% dos pedidos atrasados recebem nota 1 ou 2, há espaço para melhora mesmo que a taxa de atraso continue igual.

9.3 Evolução nas próximas fases do curso

Este relatório é o ponto de partida do projeto, que será reaproveitado e ampliado ao longo da pós-graduação, como mostra o Quadro 10.

Quadro 10 – Evolução prevista do projeto nas fases seguintes

Fase do curso	O que será desenvolvido
Fase 2 – Casos de uso	detalhar fluxos, regras de decisão e critérios de escalonamento de cada agente; desenhar o agente de relacionamento e recompra
Fase 3 – Protótipos	construir o Analista de Reviews em plataforma *low-code* e validá-lo sobre os comentários do dataset
Fase 4 – Orquestração	integrar os três agentes, a memória compartilhada e as automações de mensagens e logística
Fase 5 – Governança e escala	definir papéis, comitê de IA, políticas de uso e plano de expansão para outras áreas da empresa

Fonte: elaborado pelos autores (2026).

10 VÍDEO EXECUTIVO

O vídeo de apresentação do projeto à diretoria da Olist, com até cinco minutos, está disponível em: [inserir o link do vídeo] . O Quadro 11 resume o roteiro.

Quadro 11 – Roteiro do vídeo executivo

Tempo	Conteúdo
`0:00–0:30`	abertura: quem somos e a pergunta que a Olist nos fez
`0:30–1:45`	o que os dados mostram: atrasos, notas, comentários e recompra
`1:45–3:15`	os três agentes e como trabalham juntos (mapa e arquitetura)
`3:15–4:15`	riscos, controles e indicadores de acompanhamento
`4:15–5:00`	próximos passos e decisão solicitada: aprovar o piloto de 30 dias

Fonte: elaborado pelos autores (2026).

11 CONSIDERAÇÕES FINAIS

A análise dos 99.441 pedidos mostra que a experiência do cliente da Olist se decide depois da venda. Atrasos, entregas incompletas e falta de retorno explicam a maior parte das avaliações negativas, e a nota média cai de 4,3 para 2,3 quando o prazo não é cumprido. São problemas de

coordenação entre muitos vendedores, transportadoras e canais, e é nesse tipo de problema que agentes de IA têm mais a contribuir, porque conseguem acompanhar cada pedido, ler cada comentário e responder a qualquer hora.

A proposta começa pelo agente de menor risco e maior viabilidade, o Analista de Reviews, e avança para o Guardião Logístico e o SAC Agêntico à medida que os resultados se confirmam. Limites de autonomia, proteção de dados e supervisão humana fazem parte do desenho desde o início, e não como etapa posterior.

A principal limitação do trabalho é a idade dos dados, que cobrem de 2016 a 2018. As conclusões sobre onde estão os problemas tendem a se manter, mas os números precisam ser atualizados com a base atual da empresa antes de qualquer decisão de investimento. Nas próximas fases, o grupo vai detalhar os casos de uso, construir os protótipos e testar as hipóteses de impacto apresentadas aqui.

REFERÊNCIAS

ANTHROPIC. **Building effective agents**. [*S. l.*], 19 dez. 2024. Disponível em: https://www.anthropic.com/engineering/building-effective-agents. Acesso em: 6 out. 2026.

BRASIL. Lei nº 8.078, de 11 de setembro de 1990. Dispõe sobre a proteção do consumidor e dá outras providências. **Diário Oficial da União**: seção 1, Brasília, DF, 12 set. 1990.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). **Diário Oficial da União**: seção 1, Brasília, DF, 15 ago. 2018.

INTERNATIONAL ORGANIZATION FOR STANDARDIZATION. **ISO/IEC 42001:2023**: information technology – artificial intelligence – management system. Genebra: ISO, 2023.

LEWIS, P. *et al.* Retrieval-augmented generation for knowledge-intensive NLP tasks. *In*: CONFERENCE ON NEURAL INFORMATION PROCESSING SYSTEMS, 34., 2020. **Advances in Neural Information Processing Systems 33**. [*S. l.*]: Curran Associates, 2020. p. 9459-9474.

NATIONAL INSTITUTE OF STANDARDS AND TECHNOLOGY. **Artificial Intelligence Risk Management Framework (AI RMF 1.0)**. Gaithersburg: NIST, 2023. DOI: 10.6028/NIST.AI.100-1.

OLIST. **Brazilian E-Commerce Public Dataset by Olist**. [*S. l.*]: Kaggle, 2018. Disponível em: https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce. Acesso em: 6 out. 2026.

PARK, J. S. *et al.* Generative agents: interactive simulacra of human behavior. *In*: ACM SYMPOSIUM ON USER INTERFACE SOFTWARE AND TECHNOLOGY, 36., 2023, San Francisco. **Proceedings** [...]. New York: ACM, 2023.

RUSSELL, S.; NORVIG, P. **Inteligência artificial**: uma abordagem moderna. 4. ed. Rio de Janeiro: GEN LTC, 2022.

WENG, L. **LLM powered autonomous agents**. Lil'Log, 23 jun. 2023. Disponível em: https://lilianweng.github.io/posts/2023-06-23-agent/. Acesso em: 6 out. 2026.

WOOLDRIDGE, M. **An introduction to multiagent systems**. 2. ed. Chichester: John Wiley & Sons, 2009.

YAO, S. *et al.* ReAct: synergizing reasoning and acting in language models. *In*: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS, 11., 2023, Kigali. **Proceedings** [...]. [*S. l.*]: ICLR, 2023.